

Sieci Neuronowe i Machine Learning

Sprawozdanie z projektu zaliczeniowego

Marcin Lipowski 101681

Malika Khamidov 101325

Eryk Kilarski 101331

2026

Wprowadzenie

Celem projektu jest implementacja i analiza algorytmów uczenia maszynowego oraz sieci neuronowych od podstaw. Projekt został wykonany w języku Python z wykorzystaniem biblioteki PyTorch wyłącznie do operacji macierzowych i przechowywania tensorów.

Zaimplementowane modele:

- **Naiwny Bayes** — Categorical Naive Bayes z wygładzaniem Laplace'a
- **Drzewo decyzyjne** — kryterium Gini (klasyfikacja) i wariancja MSE (regresja)
- **Sieć dwuwarstwowa** — jawny forward/backward pass, mini-batch
- **SGD Sieć konwolucyjna** — klasyfikacja obrazów MNIST i CIFAR-10

Kod źródłowy dostępny pod adresem: github.com/MarcinLipowski/sieci-neuronowe-machine-learning

Naiwny Bayes i Drzewo Decyzyjne

Dataset — Subscribers


Dataset zawiera 1024 próbki opisujące potencjalnych subskrybentów usługi. Celem zadania jest klasyfikacja binarna. Chcemy przewidzieć czy osoba zostanie subskrybentem (Subscribes : 0/1) na podstawie czterech cech demograficznych.

Cecha	Typ	Wartości
Age	kategoryczna	senior, young adult, gen. X, adult
Sex	kategoryczna	M, F
Income	kategoryczna	low, average, high
Residence	kategoryczna	country, suburb, city
Subscribes	target	0 (64.5%), 1 (35.5%)

Brak braków danych. Klasy są lekko niezbalansowane (64.5% / 35.5%) — zastosowano stratyfikację przy podziale train/test (80/20).

Eksploracja danych

Rozkład cech względem klasy docelowej



1. Rozkład cech względem klasy docelowej

Żadna z cech nie wykazuje silnej korelacji z klasą docelową — rozkłady klasy 0 i 1 są zbliżone dla każdej wartości każdej cechy. Zapowiada to trudny problem klasyfikacyjny dla obu modeli.

Naiwny Bayes — implementacja

Zaimplementowane zostało Categorical Naive Bayes — wersję dla cech kategoriowych. W odróżnieniu od Gaussian Naive Bayes, zamiast rozkładu normalnego używa zliczania częstości z wygładzaniem Laplace'a:

$$P(\text{cecha}=v \mid c) = (\text{count}(v, c) + \alpha) / (\text{count}(c) + \alpha \times |V|)$$

gdzie $\alpha=1$ to parametr wygładzania Laplace'a, $|V|$ to liczba unikalnych wartości cechy.

Wygładzanie zapobiega zerowemu prawdopodobieństwu dla wartości niewidzianych w treningu.

Predykcja odbywa się w przestrzeni logarytmów dla stabilności numerycznej (uniknięcie underflow przy mnożeniu małych prawdopodobieństw):

$$\log P(c|x) \propto \log P(c) + \sum_i \log P(x_i | c)$$

Drzewo decyzyjne — implementacja

Zaimplementowane zostało drzewo decyzyjne dla cech kategorycznych z kryterium Gini Impurity:


$$\text{Gini}(S) = 1 - \sum_i p_i^2$$

Każdy podział tworzy tyle gałęzi ile jest unikalnych wartości cechy. Najlepsza cecha do podziału wybierana jest przez maksymalizację information gain:

$$\text{gain} = \text{Gini}(\text{rodzic}) - \sum (|S_v|/|S|) \times \text{Gini}(S_v) .$$


Parametry: max_depth=6 , min_samples_split=5 .

Wyniki i porównanie



2. Porównanie modeli — metryki

Naiwny Bayes — analiza błędów na zbiorze testowym



3. Macierz konfuzji — Naiwny Bayes

Metryka	Naiwny Bayes	Drzewo decyzyjne
Accuracy	0.6439	0.6195
Precision (kl. 1)	0.5000	0.4194
Recall (kl. 1)	0.0685	0.1781
F1 (kl. 1)	0.1205	0.2500
Accuracy treningowe	0.6593	0.6789

Oba modele osiągają accuracy równe proporcji klasy większościowej (64.5%), co wskazuje na słabą siłę dyskryminującą dostępnych cech demograficznych. Drzewo decyzyjne uzyskało wyższy $F1=0.25$ dla klasy subskrybentów dzięki zdolności do modelowania interakcji między cechami. Naiwny Bayes zakłada niezależność cech — założenie to nie jest spełnione w tym datasetcie.

Sieci Dwuwarstwowe

Zaimplementowana została sieć neuronową z jedną warstwą ukrytą bez użycia `nn.Module`.

Wszystkie obliczenia forward i backward są jawne — PyTorch używany wyłącznie do operacji macierzowych.

Architektura: wejście → [warstwa ukryta: ReLU] → [wyjście: Sigmoid lub Linear] Forward pass:

$$z_1 = X \cdot W_1^T + b_1, a_1 = \text{ReLU}(z_1) \quad z_2 = a_1 \cdot W_2^T + b_2, \hat{y} = \sigma(z_2)$$

[klasyfikacja] lub $\hat{y} = z_2$ [regresja]

Backward pass (reguła łańcuchowa):

$$\delta_2 = (\hat{y} - y) / N$$

$$\partial L / \partial W_2 = \delta_2^T \cdot a_1, \quad \partial L / \partial b_2 =$$

$$\sum \delta_2 \cdot \delta_1 = (\delta_2 \cdot W_2) \odot$$

$$\text{ReLU}'(z_1)$$

$$\partial L / \partial W_1 = \delta_1^T \cdot X, \quad \partial L / \partial b_1 = \sum \delta_1$$

Aktualizacja wag (SGD): $W = W - lr \times \partial L / \partial W$


Inicjalizacja Xavier: $W \sim N(0, \sqrt{2/n_{in}})$ — stabilizuje wariancję aktywacji przez warstwy, zapobiega zanikającemu/eksplodującemu gradientowi.

Problem XOR

XOR jest klasycznym problemem nieliniowo separowalnym — żadna prosta linia nie oddziela klas 0 i 1. Wymaga co najmniej jednej warstwy ukrytej.

x_1	x_2	XOR
0	0	0
0	1	1
1	0	1
1	1	0

Architektura: $2 \rightarrow 4 \rightarrow 1$ | **lr:** 0.05 | **Epoki:** 5000 | **Batch:** 4



4. XOR — analiza uczenia sieci dwuwarstwowej

Sieć nauczyła się XOR po około 1000 epokach (accuracy 100%). Granica decyzyjna przyjęła kształt “pasa” — dwie równoległe linie liniowe tworzone przez warstwę ukrytą, połączone przez warstwę wyjściową operacją AND.

Normy gradientów warstwy 1 oscylują silniej niż warstwy 2 — typowe zjawisko: sygnał błędu słabnie przechodząc przez W_2 (zanikający gradient w głębszych warstwach).


Titanic — klasyfikacja binarna

Dataset: 891 pasażerów Titanica, 8 cech po preprocessingu.


Preprocessing:

- Braki w kolumnie Age (177/891) uzupełniono medianą z danych treningowych (28.5 lat) — zapobiega data leakage
- Cabin usunięto (77% braków)
- Sex zakodowano binarnie (male=1, female=0)
- Embarked zakodowano one-hot (2 kolumny binarne)
- Wszystkie cechy standaryzowane do $N(0,1)$

Architektura: $8 \rightarrow 16 \rightarrow 1$ | **lr:** 0.01 | **Epoki:** 2000 | **Batch:** 32



5. Titanic — analiza uczenia sieci



6. Titanic — macierz konfuzji

Metryka	Nie przeżył (0)	Przeżył (1)
Precision	0.7869	0.7544
Recall	0.8727	0.6232
F1	0.8276	0.6825
Accuracy	0.7765	

Model poprawnie sklasyfikował 139/179 pasażerów (77.65%). Recall klasy “Przeżył” wynosi 62.32% — model przeoczył prawie 4 na 10 ocalałych, co wynika z niezbalansowania klas (61.6%/38.4%) i braku cech behawioralnych w datasetcie (kolejność wsiadania do szalup itp.).


Boston Housing — regresja

Dataset: 506 próbek okolic Bostonu, 13 cech numerycznych, target: mediana ceny domu w tys. \$ (wartość ciągła).

Architektura: 13 → 32 → 1 (wyjście liniowe) | **Funkcja straty:** MSE


Kluczowa różnica względem klasyfikacji: wyjście sieci nie ma funkcji aktywacji — neuron wyjściowy zwraca wartość ciągłą. Target normalizowany do $N(0,1)$ podczas treningu, odwracany przy ewaluacji.

Boston Housing — eksploracja danych




7. Boston Housing — eksploracja danych

Najsilniejsze korelacje z ceną: lstat ($r=-0.738$, % ludności o niskim statusie) i rm ($r=0.695$, liczba pokoi). Widoczna silna multikolinearność między cechami: tax $\leftrightarrow$ rad ($r=0.91$), nox $\leftrightarrow$ indus ($r=0.76$).




8. Boston Housing — macierz korelacji



9. Boston Housing — analiza uczenia

Boston Housing — ewaluacja na zbiorze testowym



10. Boston Housing — ewaluacja predykcji


Drzewo decyzyjne dla regresji

Zaimplementowano drzewo decyzyjne dla regresji używające wariancji (MSE) jako kryterium podziału zamiast Gini:

$$\text{gain} = \text{Var}(\text{rodzic}) - \sum (|S_v|/|S|) \times \text{Var}(S_v)$$

Parametry: `max_depth=5` , `min_samples_split=10` .

Porównanie: Drzewo decyzyjne vs Sieć neuronowa



11. Boston Housing — porównanie modeli

Metryka	Drzewo decyzyjne	Sieć neuronowa	Poprawa
MAE (tys. \$)	2.76	2.27	-17.7%
RMSE (tys. \$)	4.29	3.49	-18.6%
R^2	0.7492	0.8342	+11.3%

Sieć neuronowa przewyższa drzewo decyzyjne we wszystkich metrykach. Model myli się średnio o 2 270 \$ i wyjaśnia 83.4% wariancji cen. Drzewo (max_depth=5) osiąga $R^2=0.749$. Ograniczenie głębokości zapobiega overfittingowi kosztem dokładności. Sieć lepiej aproksymuje nieliniowe zależności (np. zależność ceny od liczby pokoi jest nieliniowa).

Sieć Konwolucyjna — MNIST

Dataset

MNIST zawiera 70 000 obrazów ręcznie pisanych cyfr (0-9) w skali szarości 28×28 pikseli. 60 000 treningowych, 10 000 testowych.

Architektura CNN

Obraz 28×28×1

```
↓ Conv2D(32 filtry, 3×3) + ReLU → 26×26×32
↓ MaxPool(2×2) → 13×13×32
↓ Conv2D(64 filtry, 3×3) + ReLU → 11×11×64
↓ MaxPool(2×2) → 5×5×64
↓ Flatten + Dropout(0.25) → 1600
↓ Linear(128) + ReLU + Dropout(0.5)
↓ Linear(10) → 10 klas
```


Parametry łącznie: 225 034

CNN używa filtrów 3×3 przesuwanych po obrazie zamiast połączeń każdy-z-każdym. Korzyści: wykrywanie lokalnych wzorców przestrzennych (krawędzie, krzywizny), współdzielenie wag, niezmienniczość na przesunięcia.

Trening: Adam (lr=0.001), CrossEntropyLoss, 10 epok, batch=64. **Sprzęt:** NVIDIA RTX 4070 Ti (CUDA 13.2).


Wyniki

CNN MNIST — historia uczenia



12. MNIST — historia uczenia

CNN MNIST — macierz konfuzji na zbiorze testowym



13. MNIST — macierz konfuzji

Epoka	Train Acc	Test Acc
1	93.44%	98.60%
5	98.53%	99.19%
10	99.00%	99.41%

Test accuracy: 99.41% — 59 błędów na 10 000 obrazów.

Charakterystyczna obserwacja: test accuracy > train accuracy przez większość treningu — efekt Dropout który podczas treningu losowo wyłącza neurony ($p=0.25$, $p=0.50$), zaniżając pozornie accuracy treningowe. Podczas ewaluacji Dropout jest wyłączony.

Najtrudniejsze cyfry: 5 (recall 99.33%), 4 (recall 99.59%) — mylone z wizualnie podobnymi cyframi.

Optymalizacja pipeline'u

Dwa wąskie gardła zostały zidentyfikowane i usunięte:

Optymalizacja	Problem	Przed	Po
num_workers + pin_memory	CPU→GPU transfer	2:30 min	49 sek
Algorytm wizualizacji	Iteracja po całym datasetcie	1:30 min	0.9 sek

num_workers uruchamia równoległe procesy CPU do ładowania danych, pin_memory=True przyspiesza transfer do pamięci GPU przez “przypięcie” RAM. Liczba workerów dobierana automatycznie: `min(cpu_count(), 8)` .

Głęboka Sieć Konwolucyjna — CIFAR-10

Dataset i problem

CIFAR-10 zawiera 60 000 kolorowych obrazów 32×32 pikseli w 10 klasach: airplane, automobile, bird, cat, deer, dog, frog, horse, ship, truck.



14. CIFAR-10 — przykłady klas

CIFAR-10 jest znacznie trudniejszy od MNIST ze względu na:

- Kolorowe obrazy (3 kanały RGB zamiast 1)
- Różnorodność wewnątrz klas (koty w różnych pozach, oświetleniu)
- Podobieństwo między klasami (cat vs dog, airplane vs bird)
- Małą rozdzielczość (32×32) przy złożonych obiektach

Architektura — VGG-like


```
32×32×3
  ↓ [Conv(64,3×3) + BN + ReLU] × 2 → MaxPool →
16×16×64
  ↓ [Conv(128,3×3) + BN + ReLU] × 2 → MaxPool →
8×8×128
  ↓ [Conv(256,3×3) + BN + ReLU] × 2 → MaxPool →
4×4×256      ↓ Flatten → Linear(512) + BN + ReLU +
Dropout(0.5)
  ↓ Linear(10) → 10 klas
Parametry łącznie: ~7 000 000
```

Ulepszenia względem MNIST CNN:

- **Batch Normalization** po każdej konwolucji — normalizuje aktywacje do $N(0,1)$ w obrębie batcha, stabilizuje uczenie i pozwala na głębsze sieci
- **3 bloki konwolucyjne** zamiast 2 — głębsza hierarchia cech
- **Data Augmentation** — RandomHorizontalFlip + RandomCrop(32, padding=4) zapobiega overfittingowi przez różnicowanie obrazów treningowych
- **ReduceLROnPlateau** — zmniejsza lr o 50% gdy brak poprawy przez 5 epok

Trening: Adam (lr=0.001, weight_decay=1e-4), 50 epok, batch=128. **Sprzęt:** NVIDIA RTX 4070 Ti, czas treningu: ~10 minut.

Wyniki




15. CIFAR-10 — historia uczenia

Etap	Epoki	LR	Test Acc
Szybki wzrost	1-10	0.001	56% → 83%
Wolna poprawa	10-36	0.001	83% → 89%
Plateau	36-42	0.001	~89%
Po redukcji LR	43-50	0.0005	90% → 91.07%

Scheduler zmniejszył lr po epoce 42 — efekt natychmiastowy: skok accuracy z 89.72% do 90.19%.

Model oscylował wokół optimum ze zbyt dużym krokiem, mniejszy lr pozwolił precyzyjniej go znaleźć.



16. CIFAR-10 — macierz konfuzji

Klasa	Recall	Klasa	Recall
automobile	95.20%	cat	79.00%
frog	96.10%	dog	88.50%
ship	95.00%	bird	85.00%

Test accuracy: 91.07% — 893 błędy na 10 000 obrazów.

Najtrudniejsza klasa: cat (recall 79.0%) — mylona głównie z psami (8.9%). Intuicyjne przy rozdzielczości 32×32 gdzie detale sylwetki są słabo widoczne.

Porównanie CNN: MNIST vs CIFAR-10

	MNIST	CIFAR-10
Architektura	2 bloki conv	3 bloki conv + BN
Parametry	225 034	~7 000 000
Epoki	10	50
Czas (RTX 4070 Ti)	49 sek	~10 min
Test accuracy	99.41%	91.07%

Różnica wyników (99.41% vs 91.07%) odzwierciedla realną trudność problemów.

Podsumowanie

Model	Problem	Metryka	Wynik
Naiwny Bayes	Subscribers — klasyfikacja	Accuracy	64.4%
Drzewo decyzyjne	Subscribers — klasyfikacja	F1 (kl. 1)	0.25
Sieć 2→4→1	XOR	Accuracy	100%
Sieć 8→16→1	Titanic — klasyfikacja	Accuracy	77.65%
Drzewo decyzyjne (regresja)	Boston Housing	R ²	0.749
Sieć 13→32→1	Boston Housing — regresja	R ²	0.834
CNN (225k param.)	MNIST — klasyfikacja obrazów	Accuracy	99.41%
Głęboka CNN (~7M param.)	CIFAR-10 — klasyfikacja obrazów	Accuracy	91.07%

Projekt potwierdza że głębokie sieci neuronowe przewyższają klasyczne metody ML (Naiwny Bayes, Drzewo decyzyjne) na złożonych problemach, szczególnie w klasyfikacji obrazów. Kluczowe techniki które pozwoliły osiągnąć dobre wyniki to Batch Normalization, Data Augmentation i adaptacyjny learning rate (ReduceLROnPlateau). Wszystkie modele zaimplementowano od podstaw z jawnymi operacjami forward i backward — bez użycia gotowych implementacji z bibliotek.